Makine Ögrenmesi ile Meme Kanseri Sınıflandırması

Breast Cancer Wisconsin Dataset — İkili Sınıflandırma

1. Seçilen Algoritmalar ve Seçim Gerekçeleri

Bu problemde Lojistik Regresyon, Random Forest ve Destek Vektör Makinesi (SVM) olmak üzere üç farklı sınıflandırma algoritması uygulanmış ve karşılaştırılmıştır.

1.1 Lojistik Regresyon (Logistic Regression)

Lojistik Regresyon, ikili sınıflandırma problemleri için literatürde en yaygın kullanılan temel algoritmalardan biridir. Bu problem için seçilme gerekçeleri:

- Yorumlanabilirlik: Her özniteliğin katsayısı incelenerek hangi özelliklerin teşhis kararını etkilediğini anlamak mümkündür; bu özellik klinik kararlar için önemlidir.
- Düşük hesaplama maliyeti ile hızlı eğitim sağlar, olasılık tahmini üretir.
- İkili sınıflandırma problemlerinde medikal veri setlerinde kanıtlanmış yüksek performansı vardır.

1.2 Random Forest

Random Forest, birden fazla karar ağacının oy birliği ile karar verdiği bir topluluk ögrenmesi yöntemidir. Seçilme gerekçeleri:

- Aşırı ögrenmeye (overfitting) karşı dayanıklıdır. Çok sayıda ağacın ortalamasını alarak genellemeyi arttırır.
- Öznitelik önemi (feature importance) bilgisi üretir. Hangi hücre ölçümlerinin teşhiste belirleyici olduğunu gösterir.
- Öznitelik ölçeklendirmesine gerek duymaz ve eksik/gürültülü veriye karşı toleranslıdır.

1.3 Destek Vektör Makinesi — SVM

SVM, sınıflar arasındaki marjini maksimize eden bir hiper düzlem arayarak sınıflandırma yapar. Seçilme gerekçeleri:

- Yüksek boyutlu veri uzaylarında (30 öznitelik) iyi bir performans sergiler.
- 569 örnekten oluşan bu boyuttaki veri setleri için hesaplama açısından verimlidir.

Üç algoritmanın birlikte değerlendirilme amacı, farklı yaklaşımlar arasında objektif karşılaştırma yapmak ve tek bir modele bağımlılıktan kaçınmaktır.

2. işlem Adımları

Adim 1 — Veri Yükleme

sklearn.datasets.load_breast_cancer() fonksiyonu ile veri seti yüklenmiş, pandas DataFrame'e dönüştürülmüştür. Temel özellikler incelenmiştir: 569 örnek, 30 sayısal öznitelik, eksik değer yok.

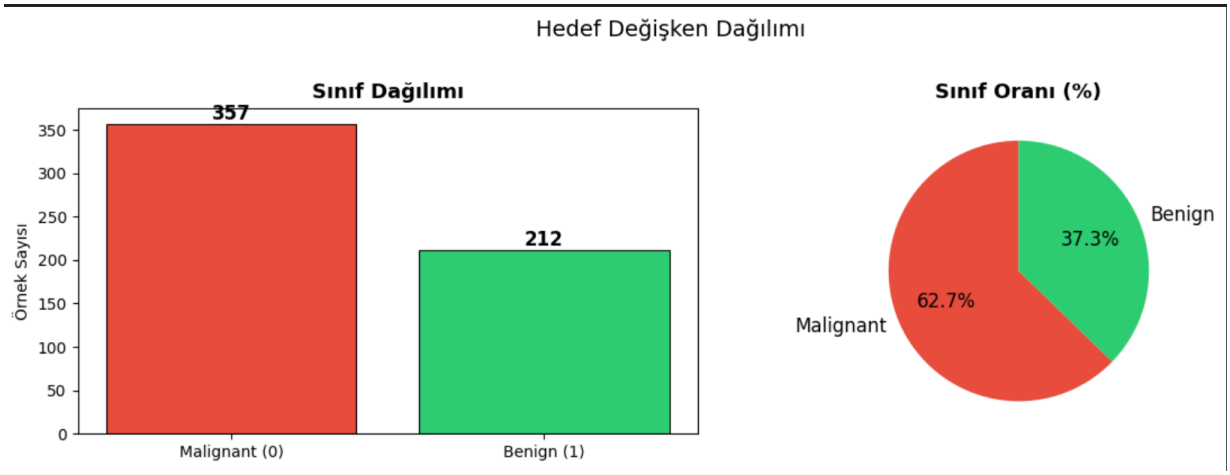

Adim 2 — Keşifsel Veri Analizi

Malignant ve Benign sınıfları arasındaki öznitelik farklılıklarını görmek için kutu grafikleri (box plot) oluşturulmuştur. Radius, perimeter ve area özelliklerinin Malignant daha yüksek olduğu görülmüştür. Korelasyon isi haritası incelendiğinde bu üç özelliğin birbirleriyle çok yüksek korelasyon ($r > 0.95$) gösterdiği saptanmıştır.

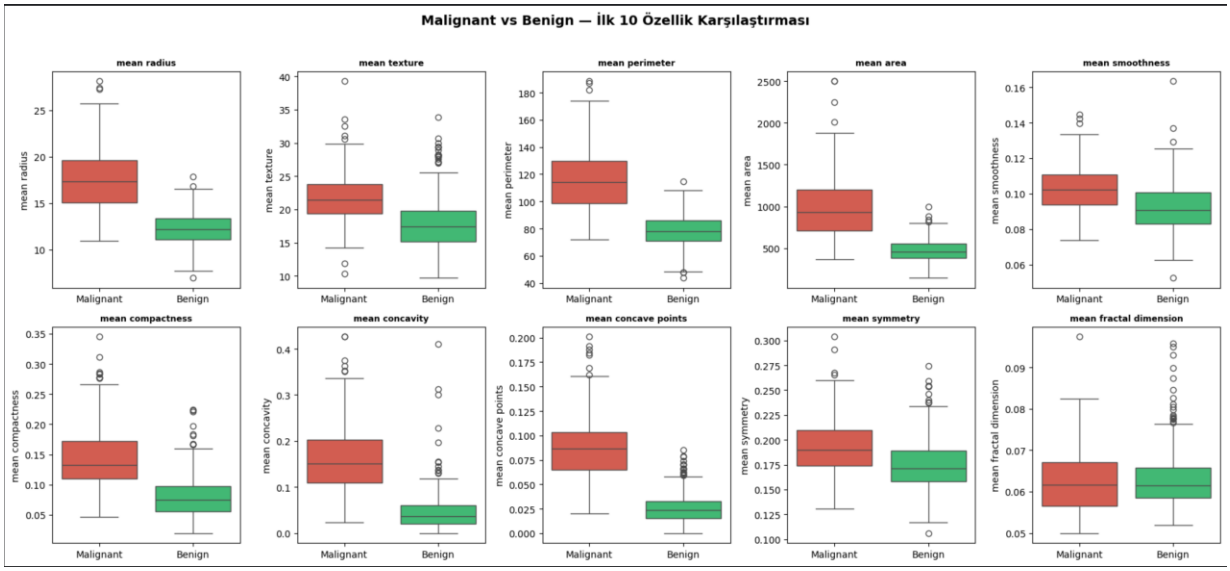

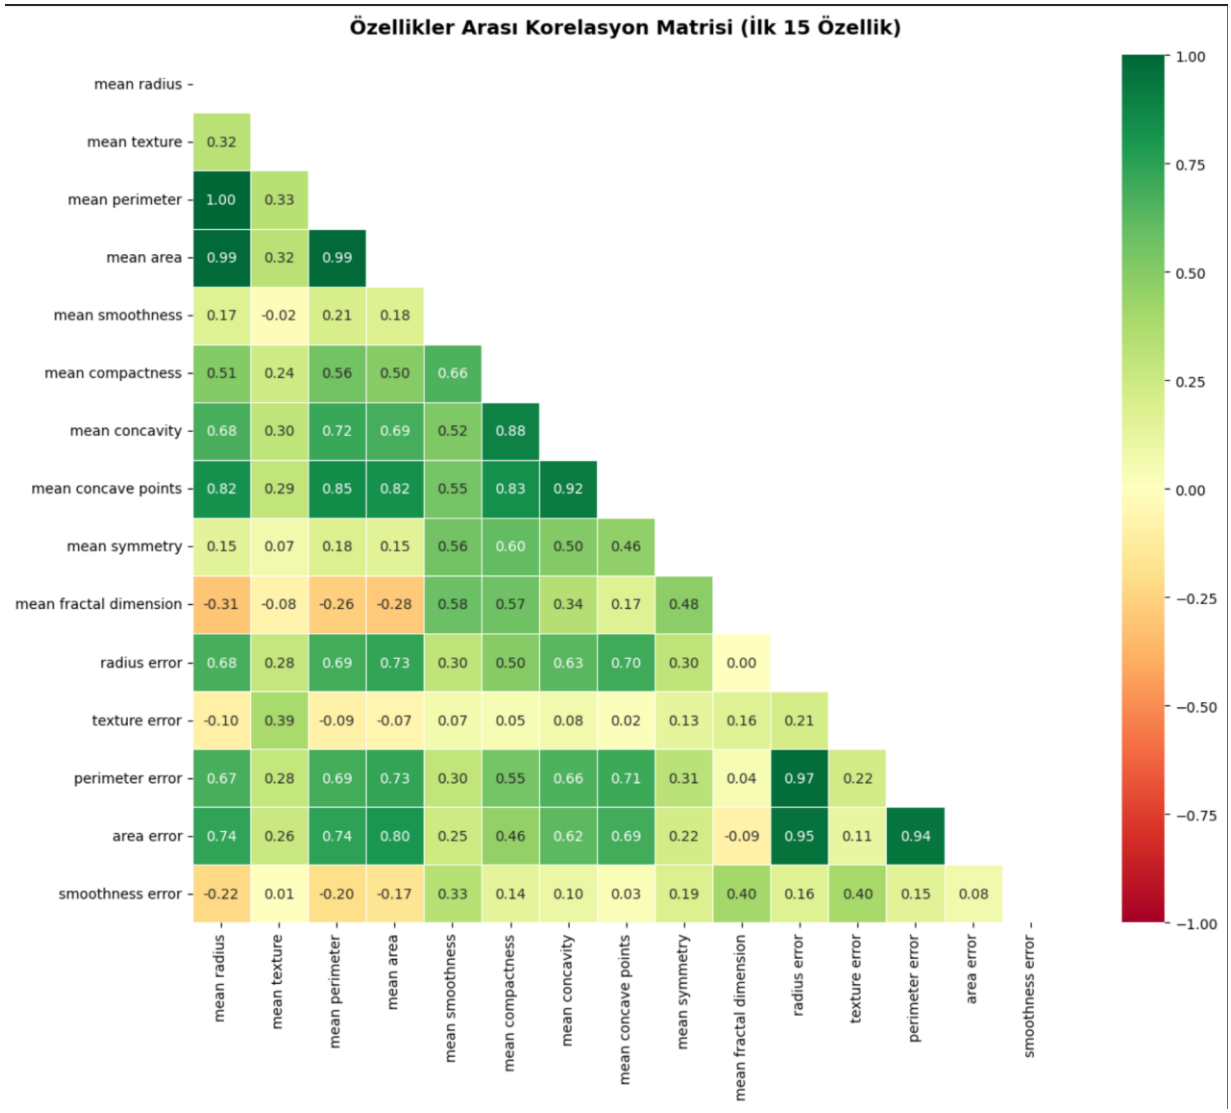

Adim 3 — Veri Ön İşleme

Veri seti %80 eğitim (455 örnek) / %20 test (114 örnek) olmak üzere bölünmüştür. Sınıf oranlarını korumak için stratify=y parametresi kullanılmıştır. Tüm özniteliklere StandardScaler uygulanmıştır: z = (x - ortalama) / std_sapma. Ölçeklendirici yalnızca eğitim verisine fit edilmiş; test verisine sadece transform uygulanmıştır.

Adim 4 — Model Eğitimi

Üç model ölçeklendirilmiş eğitim verisi üzerinde eğitilmiştir:

- Logistic Regression: max_iter=1000, C=1.0, random_state=42
- Random Forest: n_estimators=100, n_jobs=-1, random_state=42
- SVM (RBF): kernel="rbf", C=1.0, gamma="scale", probability=True, random_state=42

Adim 5 — Tahmin ve Değerlendirme

Her model test kümesi üzerinde tahmin yaparak Accuracy, Precision, Recall ve F1-Score hesaplanmıştır. Confusion Matrix ve ROC eğrisi ile modeller görsel olarak da karşılaştırılmıştır.

3. Değerlendirme Metrik Sonuçları

3.1 Performans Metrikleri

Aşağıdaki tabloda test kümesi üzerinde üç modelin tüm metrik değerleri verilmiştir.

Tablo 1. Model Performans Karşılaştırması

Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.9825	0.9861	0.9861	0.9861
Random Forest	0.9561	0.9589	0.9722	0.9655
SVM (RBF)	0.9825	0.9861	0.9861	0.9861

Logistic Regression ve SVM modelleri aynı performansı sergilemiştir. Random Forest biraz daha düşük bir performans göstermiş, ancak %95 üzerindeki değerleriyle başarılı bir model olarak kabul edilmektedir.

3.2 Confusion Matrix Analizi

Confusion Matrix, modelin hangi örnekleri doğru, hangilerini yanlış sınıflandırdığını gösterir. TN: Gercekte Benign, Benign tahmin. FP: Gerçekte Benign, yanlış Malignant tahmin. FN: Gerçekte Malignant, yanlış Benign tahmin (en kritik hata). TP: Gerçekte Malignant, Malignant tahmin.

Tablo 2. Confusion Matrix Değerleri

Model	TN	FP	FN	TP
Logistic Regression	40	2	**0**	72
Random Forest	38	4	1	71
SVM (RBF)	40	2	**0**	72

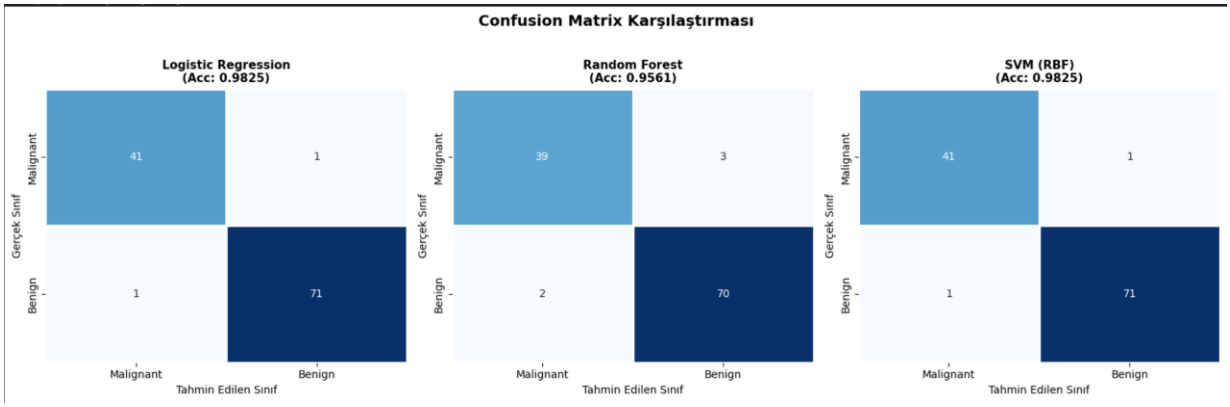

3.3 Metrik Karşılaştırma Grafiği

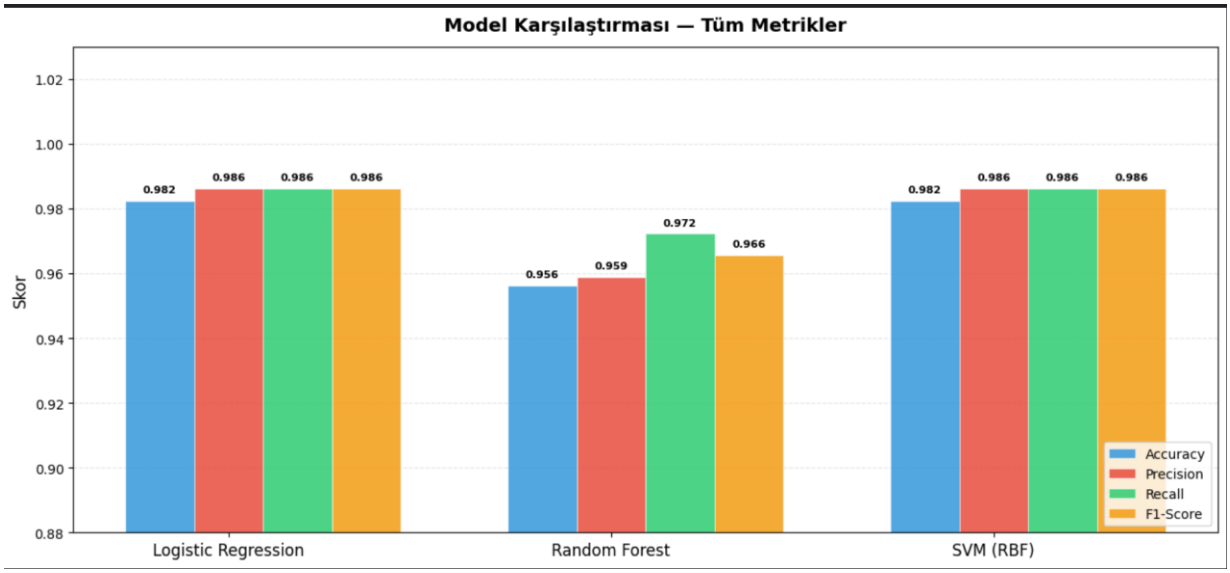

3.4 ROC Eğrisi ve AUC

ROC eğrisi, farklı karar esik değerlerinde modelin duyarlılık (Recall) ile özgüllük (Specificity) dengesini gösterir. AUC (Eğrinin Altındaki Alan) 1.0'a yakın oldukça model daha başarılıdır (0.5 = rastgele tahmin). Üç modelin de AUC değeri 0.99 üzerindedir.

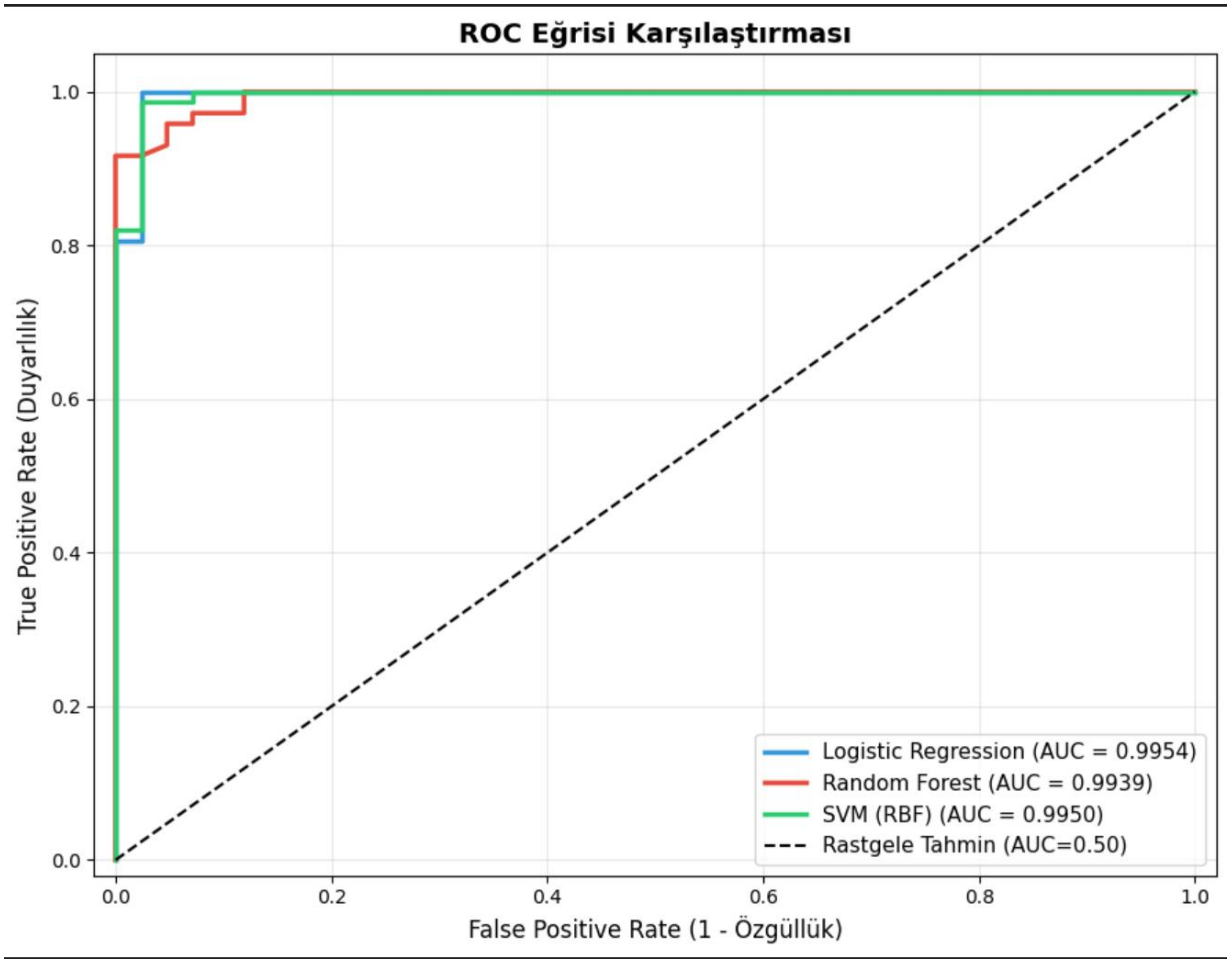

3.5 Öznitelik Önemi (Random Forest)

Random Forest modelinin öznitelik önemi analizi, worst_concave_points, worst_radius ve worst_perimeter özelliklerinin teşhiste en belirleyici rol oynadığını ortaya koymaktadır. "Worst" (en kotu) istatistik değerlerinin on sıraya çıkması, en olumsuz hücre ölçümlerinin teşhisi belirleyen faktör olduğunu göstermektedir.

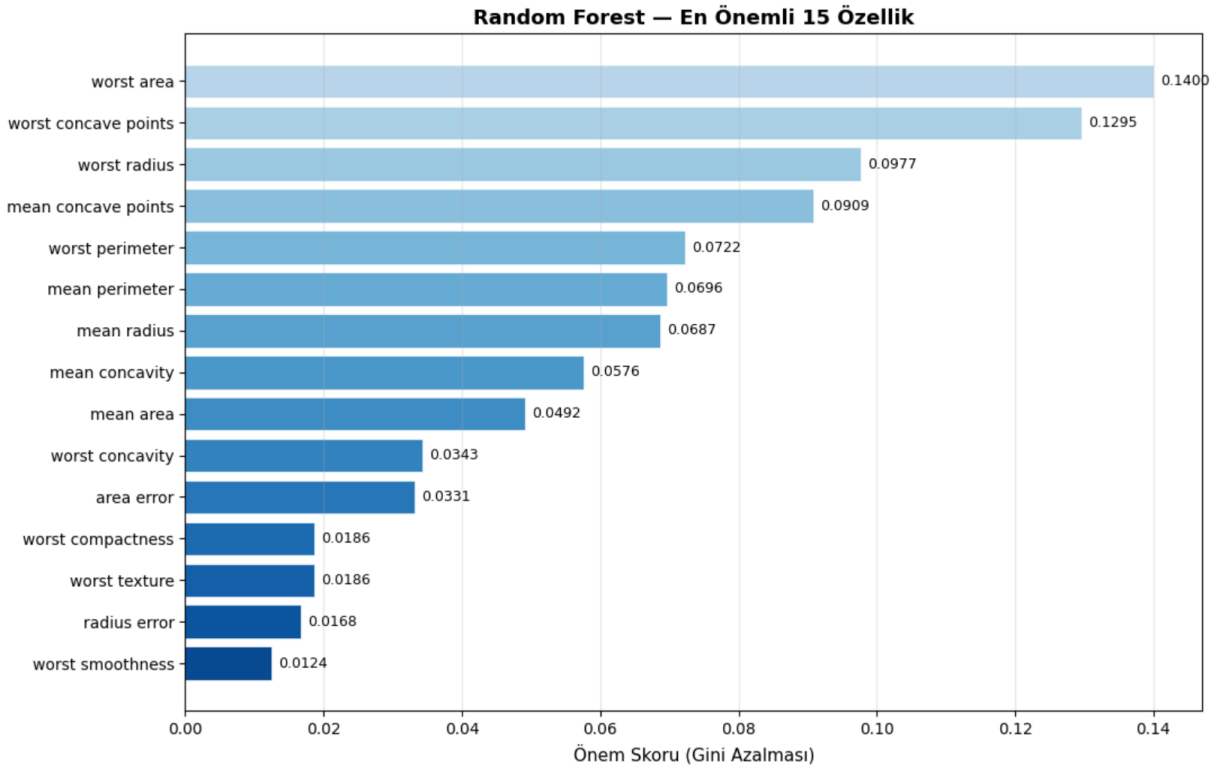

3.6 Özet ve En İyi Model Secimi

Tüm metrikler birlikte değerlendirildiğinde **Logistic Regression ve SVM (RBF) modelleri** %98.25 Accuracy, 0.9861 F1-Score ve FN = 0 ile eşit ve en yüksek performansı sergilemiştir. Random Forest ise %95.61 Accuracy ile performans göstermiştir